







A palavra é:



SEGMENTATION





SEGMENTAÇÃO

- Processo de agrupamento de pixels.
- A intenção é geralmente simplificar a imagem em agrupamentos de pixels significativos (ou seja, segmentos / objetos).
- Os segmentos são relativamente homogêneos em relação a uma ou mais características.

Para que isso serve?

Como posso utilizar isso?

SEGMENTAÇÃO

- A segmentação é a base da classificação por objetos.



É a partir da segmentação que as informações intrínsecas do objeto de forma e de textura são calculadas, e também a construção dos relacionamentos com os outros objetos é construída.



Reconhecimento de padrões e aprendizagem computacional

OBIA



Breve histórico

- 1980: primeiros desenvolvimentos da segmentação de imagem
 - Driver principal: visão industrial
- Raramente utilizado em sensoriamento remoto até o final dos anos 90
 - Pouco progresso na segmentação de imagens multibandas, algoritmos não feitos para dados EO
- Anos 2000: Elevado número de algoritmos de segmentação foram desenvolvidos
 - Disponibilidade em produtos comerciais



Conceito

OBIA: Object-Based Image Analysis

GEOBIA: Geographic Object-Based Image Analysis



Object-Based Image Analysis

- Objetos de imagem: não existem independentemente dentro de imagens digitais.
- Objeto geográfico (geo-objeto): refere-se a um objeto com determinado tamanho mínimo na superfície da Terra ou próximo a ela, com muitas propriedades permanentes e difere de seus arredores com base em propriedades específicas.



Object-Based Image Analysis

- Segundo Pinheiro e Kux (2005), a análise baseada em objeto tem como princípio dois passos:
 - ✓ segmentação/multiresolução
 - ✓ classificação
- 1º - São criados objetos em diferentes escalas (segmentação em diferentes níveis), conectados entre si, de acordo com critérios de forma e cor.
- 2º - Os objetos passam a se relacionar através da definição da rede hierárquica (herança dos atributos que descrevem a classe) e da rede semântica (estrutura lógica de relação entre as classes).



Geographic Object-Based Image Analysis

- A classificação orientada a objeto (GEOBIA) consiste na segmentação dos objetos da imagem, delimitando limites com regiões homogêneas, em vez de analisar os pixels independentemente de sua localização (DESCLÉE et al., 2006).
- De acordo com BLASCHKE et al. (2014) o GEOBIA é um paradigma em evolução, com ferramentas específicas, software, métodos, regras e linguagem, sendo cada vez mais usado para estudos que necessitam conceituar e formalizar conhecimentos.



- #2000s



- É marcada pelo lançamento de satélites com sensores capacitados à aquisição de dados de *alta a altíssima resolução espacial* (Jensen, 2009).

RPAS então?!?!?!?



Geographic Object-Based Image Analysis

- Como os pixels passam a apresentar resolução centimétrica, os métodos de classificação tradicionais, quando aplicados a essas imagens, não resultam em produtos de acurácia aceitável.
- Pesquisa e disseminação do OBIA: eCognition.
- Desde então, ampliou-se o acesso a essa inovação conceitual e tecnológica, até então restrita exclusivamente à comunidade científica.



Geographic Object-Based Image Analysis





Fig. 1. The amount of GEOBIA literature and some associated triggers (satellites and software).

Geographic Object-Based Image Analysis





Geographic Object-Based Image Analysis



<https://www.youtube.com/watch?v=PatMAWiV71M>



Geographic Object-Based Image Analysis

- **Tradicionais:** Utilizam a resposta espectral
- **OBIA:** possibilita a construção de um modelo de conhecimento que é responsável por armazenar o conhecimento do intérprete sobre a área de estudo e com base na qual os objetos são classificados.
- Como as imagens estão estruturadas em objetos, é possível extrair atributos (ou descritores) como textura, forma, relações topológicas, relação hierárquica entre os níveis de segmentação, entre outros, aproximando-se dos processos cognitivos humanos de interpretação de imagens (Navulur, 2007; Camargo et al., 2009).



OBIA x Vegetação

- REM x Vegetação?
 - Morfológicos
 - Biofísicos
- Função de distribuição de reflectância bidirecional (FDRB)

Lorenzetti (2015)

Vegetação

- Dossel
 - tipo (plantas ou árvores)
 - fechamento (%)
 - orientação
 - sistemática (p.ex., ruas 0 – 360°)
 - não-sistemática (aleatória)
- Copas (de árvores)
 - forma (p.ex., circular, cônica)
 - diâmetro (m)
- Troncos ou caules
 - densidade (unidades por m²)
 - diâmetro à altura do peito (DAP)
- Folha
 - Índice de Área Foliar (IAF ou LAI)
 - Distribuição de Ângulo Foliar (DAF) (planófilas, erectófilas)

Substrato

mesmas variáveis que as da Vegetação, acima



Geographic Object-Based Image Analysis

- Florestas tropicais:
 - Elevada complexidade estrutural
 - elevado número de espécies
 - dossel volumoso e irregularmente estratificado
 - Distribuição aleatória dos indivíduos

Aumentam a complexidade das respostas espectrais
- Outras limitações:
 - Produtos de SR
 - Altíssima resolução espacial = Elevada heterogeneidade das respostas espectrais nos dosséis.




OBIA x Vegetação

Podia ser assim né?



www.shutterstock.com · 1678662598




OBIA x Vegetação



- a) completely healthy tree or recently attacked by beetles,
- b) tree colonized by beetles,
- c) recently died tree and
- d) deadwood.

- Safonova et al. (2019).

OBIA x Vegetação



- Onish & Ise (2021).

classes

- deciduous broad-leaved tree
- deciduous coniferous tree
- evergreen broad-leaved tree

- Chamaecyparis obtuse*
- Pinus elliottii* or *Pinus taeda*
- Pinus strobus*
- non-forest

OBIA x Vegetação



deciduous
broad-leaved tree



deciduous
coniferous tree



evergreen
broad-leaved tree



*Chamaecyparis
obtuse*



Pinus elliottii or *Pinus taeda*



Pinus strobus





non-forest




- Onish & Ise (2021).

OBIA x Vegetação



deciduous
broad-leaved tree






deciduous
coniferous tree






evergreen broad-
leaved tree






*Chamaecyparis
obtuse*



Pinus elliottii or
Pinus taeda



Pinus strobus



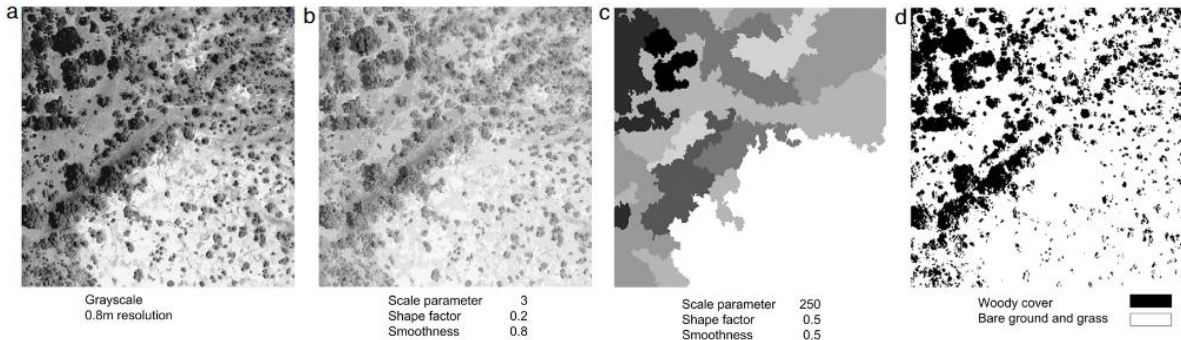
- Onish & Ise (2021).



Geographic Object-Based Image Analysis

- Os recursos em uma imagem podem variar de escala fina a grossa
- Precisa encontrar um equilíbrio (compromisso) entre muitos e poucos segmentos
- Abordagem em escala múltipla identifica recursos em escalas apropriadas

GEOBIA x Vegetação



- a) Aerial photograph of heterogeneous landscape.
- b) Fine scale segmentation.
- c) Coarse scale segmentation.
- d) Object based classification of woody cover, resulting in 97% accuracy.
- **Levick and Rogers (2008)**



Geographic Object-Based Image Analysis

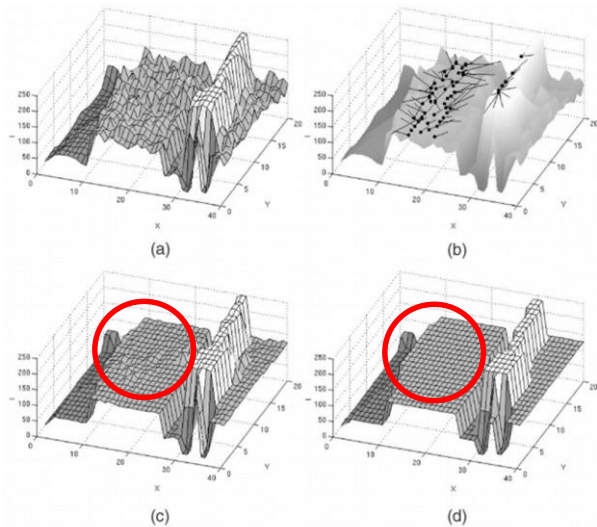
- **Crescimento da região**
 - Encontrar pixels semelhantes de uma semente e pixels vizinhos
- **Detecção de bacias hidrográficas**
 - Principalmente para imagens em escala de cinza
 - Trata a imagem como uma superfície topográfica
- **Mudança média**
 - Usado para segmentação e filtragem
 - Usa espaço de recurso e domínio espacial

Geographic Object-Based Image Analysis

Visualização do **mean shift-based filtering** e **segmentação** em nível de cinza.


- a) Entrada.
- b) Mean shift trajetetos para os pixels no platô e na linha. O pontos pretos são pontos de convergência.
- c) Resultado do Filtering (h_s, h_r)* = (8,4).
- d) Resultado da segmentação

* H_s e h_r são a largura de banda do kernel empregado







Geographic Object-Based Image Analysis



Original




$(h_s, h_r) = (8, 8)$




$(h_s, h_r) = (8, 16)$



Geographic Object-Based Image Analysis



$$(h_s, h_r) = (16, 4)$$




$$(h_s, h_r) = (16, 8)$$



$$(h_s, h_r) = (16, 16)$$



Geographic Object-Based Image Analysis



$$(h_s, h_r) = (32, 4)$$



$$(h_s, h_r) = (32, 8)$$



$$(h_s, h_r) = (32, 16)$$



Geographic Object-Based Image Analysis

Quais informações obtemos com a segmentação?

- **Espectral:**
 - Média
 - Variância
 - Alcance
 - Índices
- **Espacial:**
 - Área
 - Formato
 - Local



Geographic Object-Based Image Analysis

Table 4
Available software/tool for object-based segmentation.

Tool/Software	Reference/Developer	Website	Algorithm	Availability
InterSeg	Happ et al. (2016)	http://www.lvc.ele.puc-rio.br/wp/?cat=41	Region-based (on cloud)	Available upon request
SEGEN	Gofman (2006)	http://www.research.ibm.com/haifa/projects/image/seggen/index.html	Region-based	Commercial
BerkeleyImgSeg	Clinton et al. (2010)	http://www.imageseg.com/	Region-based	Commercial
Orfeo Toolbox	Grizonnet et al. (2017)	http://www.orfeo-toolbox.org/otb/	Region-based	Freeware
RHSeg	Tilton et al. (2012)	https://opensource.gsfc.nasa.gov/projects/HSEG/	Region-based	Evaluation copy
IMAGINE Spatial Modeler	Hexagon Geospatial	http://community.hexagongeospatial.com/t5/IMAGINE-Spatial-Modeler/tkb-p/eTSpatialModeler	Edge-based	Commercial
ENVI Feature Extraction	Harris Geospatial Solutions	https://www.harrisgeospatial.com/docs/routines-164.html	Edge-based	Commercial
IDRISI GIS Tool	Clark Labs	https://clarklabs.org/tererset/idrisi-gis/	Edge-based	Commercial
GRASS GIS	Neteler et al. (2008)	https://grass.osgeo.org/grass74/manuals/i.segment.html	Region- and edge-based	Freeware
Object Analyst	PCI Geomatics	http://www.pcigeomatics.com/geomatica-help/concepts/focus_c/oa_intro.html	Region-based	Commercial
eCognition Developer	Baatz and Schäpe (2000)	http://www.ecognition.com/suite/ecognition-developer	Region- and edge-based	Commercial
SPRING	Câmara et al. (1996)	http://www.dpi.inpe.br/spring/english/index.html	Region- and edge-based	Freeware
EDISON	Comaniciu and Meer, (2002)	http://coewww.rutgers.edu/riul/research/code/EDISON/doc/help.html	Region-based	Freeware
SCRM	Castilla et al. (2008)	http://www.castlink.ca/scrm/scrm	Region- and edge-based	Freeware
RSGISLib	Bunting et al., (2014)	https://www.rsgislib.org/	Region-based	Freeware
SAGA	Böhner et al., (2006)	http://www.saga-gis.org/en/index.html	Region- and edge-based	Freeware
Feature Analyst	Opitz and Blundell, (2008)	https://www.textronsystems.com/what-we-do/geospatial-solutions/feature-analyst	Semantic	Commercial
ArcGIS Spatial Analyst	ESRI	http://desktop.arcgis.com/en/arcmap/10.3/tools/spatial-analyst-toolbox/an-overview-of-the-segmentation-and-classification-tools.htm	Region-based	Commercial
GeoSegment	Chen (2018)	http://130.15.95.215/lagisa/	Region-based	Online tool, available upon registration



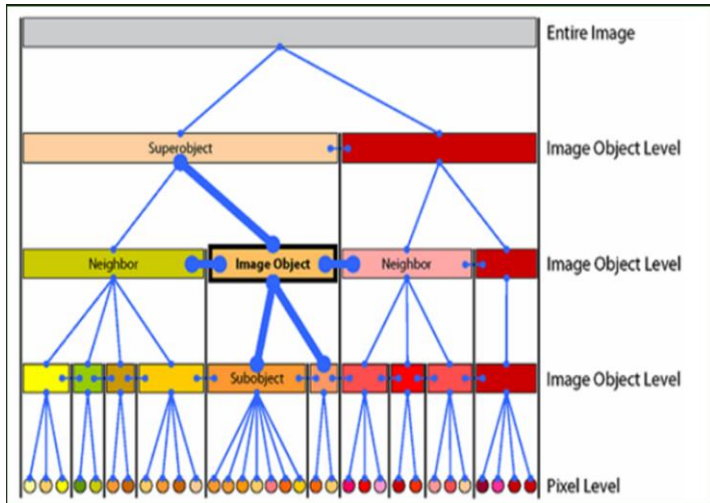
Geographic Object-Based Image Analysis

Multi-escala (hierárquico)

Multi-Origem

Multi-Resolução

Multi-Temporal





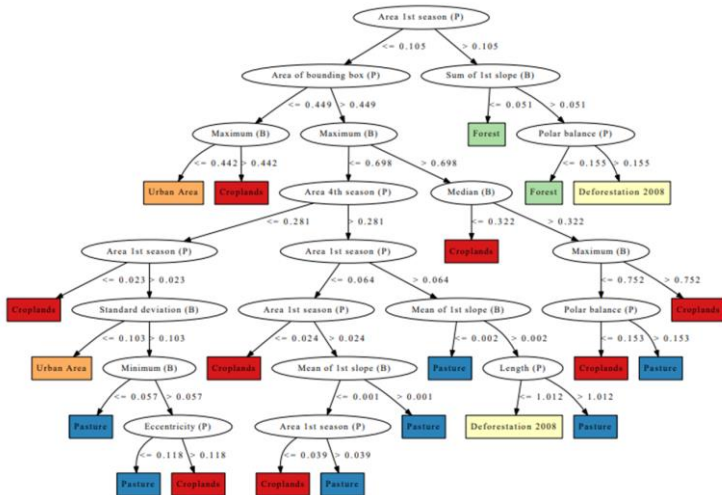
Geographic Object-Based Image Analysis



Geographic Object-Based Image Analysis

13 níveis

Kappa = 0,82



Geographic Object-Based Image Analysis

Table 2: Segmentation-based spectral features.

Name	Description	Formula	Range	Unit
Amplitude	Defines the maximum pixel value minus the minimum pixel value.	$px_{\max} - px_{\min}$	≥ 0	px
Dissimilarity	Measures how different are the GLCM elements. Higher values mean regions with high contrast.	$\sum_{i=1}^{D-1} \sum_{j=1}^{D-1} p_{ij} \cdot i - j $	≥ 0	–
Entropy	Measures the disorder in an image. When the image is not uniform, many GLCM elements have small values, resulting in large entropy.	$-\sum_{i=1}^{D-1} \sum_{j=1}^{D-1} p_{ij} \cdot \log p_{ij}$	≥ 0	–
Homogeneity	Assumes higher values for smaller differences in the GLCM.	$\sum_{i=1}^{D-1} \sum_{j=1}^{D-1} \frac{p_{ij}}{1 + (i - j)^2}$	≥ 0	–
Mean	Returns the average value for all N pixels inside the region.	$\frac{\sum_{i=1}^N px_i}{N}$	≥ 0	px
Mode	Returns the most occurring value (mode) for all N pixels inside the region. The first mode is assumed for multimodal cases.		≥ 0	px
Std	Returns the standard deviation of all N pixels (μ is the mean value).	$\sqrt{\frac{1}{N-1} \sum_{i=1}^N (px_i - \mu)^2}$	≥ 0	px



Geographic Object-Based Image Analysis

Table 3: Segmentation-based spatial features. The unit $\#px$ means the amount of pixels.

Name	Description	Formula	Range	Unit
Angle	Represents the main direction of a region. It is retrieved by the angle of the biggest radius of the minimum circumscribing ellipse.		$[0, \pi]$	rad
Area	Returns the area of the region. When measured in pixels is equal to N .		≥ 0	$\#px^2$
Box area	Returns the bounding box area of a region, measured in pixels.		≥ 0	$\#px^2$
Circle	Relates the areas of the region and the smallest circumscribing circle. R stands for maximum distance between the centroid and all vertices.	$1 - \frac{N}{\pi R^2}$	$[0, 1)$	$\#px$
Elliptic fit	Finds the minimum circumscribing ellipse to the region and returns the ratio between the area and the ellipse area.		$[0, 1]$	–
Fractal dimension	Returns the fractal dimension of a region.	$2 \frac{\log \frac{perimeter}{4}}{\log N}$	$[1, 2]$	–
Gyration radius	Equals the average distance between each pixel position in one region and its centroid. Smaller values stand for regions similar to a circle.	$\frac{\sum_{i=1}^N pos_i - pos_c }{N}$	≥ 0	$\#px$
Length	It is the height of the region's bounding box.		≥ 0	$\#px$
Perimeter	It is the amount of pixels in the region's border.		≥ 0	$\#px$
Perimeter area ratio	Calculates the ratio between the perimeter and the area of a region.	$\frac{perimeter}{N}$	≥ 0	$\#px^{-1}$
Rectangular fit	Is the ration between the region's are and the minimum rectangle outside the region. Higher values stand for regions similar to a rectangle.		$[0, 1]$	–
Width	It is the width of the region's bounding box.		≥ 0	$\#px$

Geographic Object-Based Image Analysis

Table 5: Multi-temporal features for describing cyclic events.

Name	Description	Type	Range
Amplitude	The difference between the cycle's maximum and minimum values. A small amplitude means a stable cycle.	Basic	[0, 1]
Area	Area of the closed shape. A higher value indicates a cycle with high EVI values.	Polar	≥ 0
Area per Season	Partial area of the closed shape, proportional to a specific quadrant of the polar representation. High value in the summer season can be related to the phenological development of a cropland.	Polar	≥ 0
Circle	Returns values close to 1 when the shape is more similar to a circle. In the polar visualization, a circle means a constant feature.	Polar	[0, 1]
Cycle's maximum	Relates the overall productivity and biomass, but it is sensitive to false highs and noise.	Basic	[0, 1]
Cycle's mean	Average value of the curve along one cycle.	Basic	[0, 1]
Cycle's minimum	Minimum value of the curve along one cycle.	Basic	[0, 1]
Cycle's std	Standard deviation of the cycle's values.	Basic	≥ 0
Cycle's sum	When using vegetation indices, the sum of values over a cycle means the annual production of vegetation.	Basic	≥ 0
Eccentricity	Return values close to 0 if the shape is a circle and 1 if the shape is similar to a line.	Basic	[0,1]
First slope maximum	It indicates when the cycle presents some abrupt change in the curve. The slope between two values relates the fastness of the greening up or the senescence phases.	Basic	[-1, 1]
Gyration radius	Equals the average distance between each point inside the shape and the shape's centroid. Smaller values stand for shapes similar to a circle.	Polar	≥ 0
Polar balance	The standard deviation of the areas per season, considering the 4 seasons. Small value point to constant cycles, e.g. the EVI of water (with a small Area), or forest (with a medium Area).	Polar	≥ 0



Geographic Object-Based Image Analysis

Table 4: Landscape-based features. When the unit is hectares, the value is divided by 10^4 .

Name	Description	Formula	Range	Unit
Class area	The metric <i>CA</i> means the sum of areas of a cell.	$\sum_{j=1}^n a_j$	≥ 0	ha
Percent land	<i>%Land</i> equals the sum of the areas (m^2) of all patches of the corresponding patch type, divided by total landscape area (m^2). <i>%Land</i> equals the percentage the landscape comprised of the corresponding patch type.	$\frac{\sum_{j=1}^n a_j}{A} \times 100$	[0, 1]	%
Patch density	<i>PD</i> equals the number of patches of the corresponding patch type divided by total landscape area.	$\frac{n}{A}$	≥ 0	Patches
Mean patch size	<i>MPS</i> equals the sum of the areas (m^2) of all patches of the corresponding patch type, divided by the number of patches of the same type.	$\frac{\sum_{j=1}^n a_j}{n} 10^{-4}$	≥ 0	ha
Patch size std	<i>PSSD</i> is the root mean squared error (deviation from the mean) in patch size. This is the population standard deviation, not the sample standard deviation.	$\sqrt{\frac{\sum_{j=1}^n (a_j - MPS)^2}{n}} 10^{-4}$	≥ 0	ha
Landscape shape index	<i>LSI</i> equals the sum of the landscape boundary and all edge segments (m) within the boundary. This sum involves the corresponding patch type (including borders), divided by the square root of the total landscape area (m^2).	$\frac{\sum_{j=1}^n e_j}{2 \sqrt{\pi \times A}}$	≥ 1	—



Principais desafios da GEOBIA

- Segmentação de objetos lineares
 - Segmentação a partir de agrupamento de pixels de baixo nível.
 - Segmentação em várias escalas
 - Otimização de parâmetros de segmentação
 - Avaliação dos resultados da segmentação
-
- Hossain and Chen (2019)



Tendências da GEOBIA

- Incorporar superpixels a outros modelos, como modelo de fusão probabilística (Zhang et al., 2015).
- Função de densidade de probabilidade (Liu et al., 2017).
- Fusão de região adaptativa (Ko e Ding, 2016).
- Finalidade de agrupamento dependente (Maboudi et al., 2016).
- Corte normalizado em múltiplas escalas e com várias características (Zhong et al., 2016).
- Árvore de abrangência mínima (Wang et al., 2017)
- Árvore de mesclagem binária (Su e Zhang, 2018), para identificar a escala e os parâmetros ideais, bem como minimizar o problema de sub e/ou super segmentação.
- Hossain and Chen (2019)



Direções futuras da GEOBIA

- **Abordagem hexagonal da MRS baseada em células (Hofmann e Tiede, 2014)**, considera o hexágono elegível para representar a superfície da terra com mais eficiência, já que os pixels são entidades não naturais. Esse método proporcionou melhores resultados quando comparado ao MRS baseada em célula quadrada, especialmente na segmentação linear e redonda, características de forma.
- **Agrupamento de pixels de baixo nível**, é uma abordagem mais natural e eficiente.
- **Hossain and Chen (2019)**



Direções futuras da GEOBIA

- Qual é a escala de segmentação ideal para objetos de imagem diferentes dentro de uma cena?”
- Definição de critérios de homogeneidade ou heterogeneidade?
- Apesar de promissores, os algoritmos de segmentação pelo **Método híbrido** estão enfrentando problemas devido à implementação complexa e a falta de software e ferramentas disponíveis.
- Hossain and Chen (2019)



Reconhecimento de padrões e aprendizagem computacional

OBIA - Mean Shift



Mean Shift

- Conceito: Uma técnica generalista não paramétrica
- Visa:
 - Análise de um espaço complexo de característica multimodal, e;
 - Delimitação de clusters arbitrariamente moldados nele.
- Não exige um conhecimento anterior sobre a quantidade de grupos, nem restringe o formato destes agrupamentos
- Utiliza o conceito das janelas de “Parzen”



Mean Shift

$$\hat{f}(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n K_{\mathbf{H}}(\mathbf{x} - \mathbf{x}_i)$$

Função genérica estimadora de densidade.

- Trata-se de um método iterativo que estima a moda (região mais densa) de distribuições multivariadas obtidas no espaço amostral




Mean Shift

- Envolve basicamente três etapas:
 1. estimar a densidade para uma região de interesse (janela do Kernel),
 2. encontrar a moda da densidade, e
 3. associar cada ponto a uma moda.




Mean Shift






Mean Shift






Mean Shift






Mean Shift






Mean Shift






Mean Shift






Mean Shift






Mean Shift






Mean Shift








Mean Shift



Mean Shift





Mean Shift

- Centro de massa

$$\hat{f}_{h,G}(\mathbf{x}) = \frac{c_{g,d}}{nh^d} \sum_{i=1}^n g\left(\left\|\frac{\mathbf{x} - \mathbf{x}_i}{h}\right\|^2\right)$$


- Vetor Mean Shift

$$\mathbf{m}_{h,G}(\mathbf{x}) = \frac{\sum_{i=1}^n \mathbf{x}_i g\left(\left\|\frac{\mathbf{x} - \mathbf{x}_i}{h}\right\|^2\right)}{\sum_{i=1}^n g\left(\left\|\frac{\mathbf{x} - \mathbf{x}_i}{h}\right\|^2\right)} - \mathbf{x}$$



Mean Shift

- **Cluster:**
 - Todos os pontos na bacia de atração de uma moda
- **Bacia de atração:**
 - Região para a qual todas as trajetórias conduzem para mesma moda.
 - Modas situadas a uma distância menor do que a largura da janela de observação são fundidas em um mesmo cluster





Mean Shift

- Regra geral:
 - h muito pequeno: A função de densidade de probabilidade sobrepõe-se ao ruído presente nos dados. Excesso de clusters
 - h muito grande: Os detalhes dos dados iniciais são suavizados
Poucos clusters



Mean Shift

- **Técnicas para seleção:**
 - **Fator estatístico:** Forneça o melhor equilíbrio entre o viés e a variância do estimador
 - **Estabilidade da decomposição:** Para um mesmo número final de clusters, o maior detalhamento possível
 - **Qualidade da decomposição:** Variabilidade inter x intra-cluster ou avalia o isolamento e conectividade dos clusters delineados
 - **Definido pelo usuário:** “top-down information”

Mean Shift



Original



$(h_x, h_y) = (8, 8)$



$(h_x, h_y) = (8, 16)$



$(h_x, h_y) = (16, 4)$



$(h_x, h_y) = (16, 8)$




$(h_x, h_y) = (16, 16)$



$(h_x, h_y) = (32, 4)$



$(h_x, h_y) = (32, 8)$



$(h_x, h_y) = (32, 16)$



Mean Shift

- Aplicável à diversas tarefas computacionais aonde modelos paramétricos não são adequados;
- Facilmente integrada a sistemas mais complexos, já que o único controle de entrada é a janela do kernel;
- O procedimento mean shift não é computacionalmente oneroso;
- A solução completa para a segmentação autônoma de imagens é a LARGURA DE BANDA ADAPTATIVA, mais adequada para a estrutura local da variável.



Tarefa COLAB

1. Busquem artigos que sobre diferentes algoritmos de GEOBIA que possam ser implementados em R no COLAB.
2. Individual.
3. Deve conter o código básico do algoritmo e descrever sua implementação.



Referências

Onishi, M., Ise, T. Explainable identification and mapping of trees using UAV RGB image and deep learning. Sci Rep 11, 903 (2021). <https://doi.org/10.1038/s41598-020-79653-9>

Safonova, A.; Tabik, S.; Alcaraz-Segura, D.; Rubtsov, A.; Maglinets, Y.; Herrera, F. Detection of Fir Trees (*Abies sibirica*) Damaged by the Bark Beetle in Unmanned Aerial Vehicle Images with Deep Learning. Remote Sens. 2019, 11, 643. <https://doi.org/10.3390/rs11060643>

Lorenzetti, J. A. Princípios Físicos de Sensoriamento Remoto. 2015. 292p.

Mohammad D. Hossain, Dongmei Chen. Segmentation for Object-Based Image Analysis (OBIA): A review of algorithms and challenges from remote sensing perspective, ISPRS Journal of Photogrammetry and Remote Sensing, v. 150, 2019. <https://doi.org/10.1016/j.isprsjprs.2019.02.009>.