

### Regressão linear com múltiplas variáveis – RESUMO

Hypothesis: 
$$h_{\theta}(x) = \theta^T x = \theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

Parameters:  $\theta_0, \theta_1, \dots, \theta_n$ 

Cost function:

$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})^2$$

#### Gradient descent:

Repeat {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \dots, \theta_n)$$

(si

(simultaneously update for every  $j = 0, \dots, n$ )



Reconhecimento de padrões e aprendizagem computacional

# Regressão Logistica





#### Regressão Logística



$$h_{\theta}(x)$$
 at 0.5:

If 
$$h_{\theta}(x) \geq 0.5$$
, predict "y = 1"

If 
$$h_{\theta}(x) < 0.5$$
, predict "y = 0"

### Regressão Logística

Classification: y = 0 or 1

$$h_{\theta}(x)$$
 can be > 1 or < 0

Logistic Regression:  $0 \le h_{\theta}(x) \le 1$ 




# Regressão Logística - Representação das hipóteses

Logistic Regression:  $0 \le h_{\theta}(x) \le 1$ 

$$h_{\theta}(x) = \theta^T x$$

Função sigmoide ou Função logística





# Regressão Logística - Representação das hipóteses

$$h_{ heta}(x) = Probabilidade estimada de y=1 com "x"$$
 $de entrada$ 

# Exemplo:

If 
$$x=\left[\begin{array}{c} x_0 \\ x_1 \end{array}\right]=\left[\begin{array}{c} 1 \\ \text{Reflectância NIR} \end{array}\right]$$
 
$$h_{\theta}(x)=0.7$$

Probabilidade de y=1, dado "x", parametrizado por θ



# Regressão Logística – Representação das hipóteses

Suponha que desejamos prever, a partir de dados "x" sobre uma planta, seja Buva (y=1) ou não (y=0).

Nosso classificador de regressão logística gera, para uma planta específica:  $h\theta(x) = P(y=1|x;\theta) = 0.7$ 

Estimamos que haja 70% de chance de essa planta ser Buva. Qual deve ser nossa estimativa para P(y=0|x;i), a probabilidade da planta NÃO ser Buva?

a) 
$$P(e = 0 | x; i) = 0.3$$

**b)** 
$$P(e = 0 | x; \theta) = 0.7$$

C) 
$$P(e=0 \mid x; \theta) = 0.7^2$$


d) 
$$P(e=0 | x; i) = 0.3 \times 0.7$$



#### Regressão Logística – Limite de decisão


# **Logistic regression**

$$h_{\theta}(x) = g(\theta^T x)$$
$$g(z) = \frac{1}{1 + e^{-z}}$$







### Regressão Logística – Limite de decisão





# Regressão Logística - Representação das hipóteses

Considere uma regressão logística com duas variáveis x1 e x2.  $\theta_0 = 5$ ,  $\theta_1 = -1$ ,  $\theta_2 = 0$ 












### Regressão Logística – Limite de decisão



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_1^2 x_2 + \theta_5 x_1^2 x_2^2 + \theta_6 x_1^3 x_2 + \dots)$$



Training set: 
$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \cdots, (x^{(m)}, y^{(m)})\}$$

m examples 
$$x \in \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}$$
  $x_0 = 1, y \in \{0, 1\}$ 


$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

How to choose parameters  $\theta$  ?



Linear regression: 
$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \frac{1}{2} \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$


$$Cost(h_{\theta}(x^{(i)}), y^{(i)}) = \frac{1}{2} \left( h_{\theta}(x^{(i)}) - y^{(i)} \right)^{2}$$






$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1\\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Se 
$$y=1$$
:



# Se *y*=0:





$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$
$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1\\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Note: y = 0 or 1 always

$$J(\theta) = \frac{1}{m} \sum_{i=1}^{m} \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$
$$= -\frac{1}{m} \left[ \sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

To fit parameters  $\theta$ :

$$\min_{\theta} J(\theta)$$

To make a prediction given new x:

Output 
$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

### Regressão Logística – Gradiente descedente

#### **Gradient Descent**

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

# Want $\min_{\theta} J(\theta)$ :


Repeat {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta)$$

 $\{$  (simultaneously update all  $heta_j$ )




### Example: Linear regression (housing prices)




Então, overfitting é:




#### Example: Logistic regression












- 1- Reduzir o número de variáveis
  - Selecionar manualmente quais variáveis entrar;
  - Usar algum algoritmo de seleção de variáveis.

### 2- Regularização

- Mantém todas variáveis, mas reduz a magnitude/valores
- Funciona melhor quando têm muitas variáveis, cada uma contribui um pouco para prever.



# O problema do Overfitting – Regularização



Suppose we penalize and make  $\theta_3$ ,  $\theta_4$  really small.

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



# O problema do Overfitting - Regularização

- 1- Valores pequenos para os parâmetros
  - hipótese mais "simples"
  - Menor propensão ao overfitting

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



# O problema do Overfitting – Regularização

$$J(\theta) = \frac{1}{2m} \left[ \sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^{n} \theta_j^2 \right]$$

$$\min_{\theta} J(\theta)$$




# O problema do Overfitting – Regularização

In regularized linear regression, we choose  $\theta$  to minimize

$$J(\theta) = \frac{1}{2m} \left[ \sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \underline{\lambda} \sum_{j=1}^{n} \theta_j^2 \right]$$

What if  $\lambda$  is set to an extremely large value (perhaps for too large for our problem, say  $\lambda=10^{10}$ )?



$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$



# O problema do Overfitting – Regularização Reg. Linear

$$J(\theta) = \frac{1}{2m} \left[ \sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^{n} \theta_j^2 \right]$$

$$\min_{\theta} J(\theta)$$

# O problema do Overfitting – Regularização Reg. Linear Gradient descent

Repeat {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_0^{(i)}$$

$$\theta_j := \theta_j - \alpha \quad \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$(j = 0, 1, 2, 3, \dots, n)$$

$$\theta_j := \theta_j (1 - \alpha \frac{\lambda}{m}) - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)}$$



### O problema do Overfitting – Regularização Eq. Normal

#### Normal equation


$$X = \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix}$$

$$y = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$



### O problema do Overfitting – Regularização Reg. Log.

#### Regularized logistic regression.



$$J(\theta) = -\left[\frac{1}{m} \sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))\right]$$

# O problema do Overfitting – Regularização

#### **Gradient descent**

Repeat {  $\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_0^{(i)}$  $\theta_j := \theta_j - \alpha \qquad \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$  $(j = \mathbb{X}, 1, 2, 3, \dots, n)$ 

